

# **Convolutional Neural Network**

**ResNet** 

2022.02.21

황성아

### **Abstract**

# "마이크로소프트에서 개발, ILSVRC 2015 우승"




Figure 1. Training error (left) and test error (right) on CIFAR-10 with 20-layer and 56-layer "plain" networks. The deeper network has higher training error, and thus test error. Similar phenomena on ImageNet is presented in Fig. 4.

20층의 네트워크와 56층의 네트워크로 실험 -> 56층 레이어가 오히려 더 안좋은 성능을 보임

성능을 높이기 위해 가장 쉽게 생각하는 방 법은 layer 를 깊게 쌓는 것


하지만, layer 가 너무 깊어지면 gradient vanishing(기울기 소실) 등의 문제 발생

[[다라서, ResNet은 깊은 네트워크를 학습시 키기 위해 Residual(잔차)를 학습하는 방법 적용

Deep Residual Learning for image Recognition(CVPR 2016) [Paper]

### **ResNet Architecture**

#### "Residual Learning을 이용해 네트워크의 최적화 난이도를 낮춤"




input x를 받아 2개의 weighted layer 를 거쳐 output H(x)를 내며, 다음 layer의 입력으로 적용

목표: 최적의 H(x) 구하기

Output에서 input을 뺀 값인 잔차: F(x) = H(x)-x 를 학습-> Rseidual Learning

목표: F(x)가 001 되도록

# **Residual Learning**



<ResNet>


결과 값에 Input 값 x를 더해주는 것 하나 추가

결과 값에 x를 더한 F(x)+x 가 원래 의도했던 H(x)와 같아지도 록 유도 -> 잔차: F(x) = H(x)-x 가 0이 되도록

앞서 학습된 정보 그대로 가져오고 추가적으로 F(x) 만 학습할 수 있어 각각 학습해야 했던 H(x)보다 학습이 훨씬 쉬움

**Altruistic Data Scientists** 

# **Residual Learning**




$$output = X_{l+1}$$
 
$$X_{l+1} = f(F(X_l, W_l) + h(X_l))$$
 Convolutional Shortcut layers

$$X_L = X_l + \sum_{i=1}^{L-1} F(X_i, W_i)$$

$$\frac{\partial \varepsilon}{\partial X_l} = \frac{\partial \varepsilon}{\partial X_L} \frac{\partial X_L}{\partial X_l} = \frac{\partial \varepsilon}{\partial X_L} (1 + \frac{\partial}{\partial X_l} \sum_{i=1}^{L-1} F(X_i, W_i))$$

앞의 Gradient가 그대로 더해지면서 Vanishing 문제 해결 (Weight layer를 고려하지 않고 더해지는 형태)

#### "기본적으로 VGG와 비슷, 건너건너 shortcut을 더하는 형태"



실선: Identity Shortcut, 점선: Projection Shortcut

# **Identity Shortcut VS Projection Shortcut**

#### "Residual 네트워크를 구성할 때 입력과 출력의 차원이 같아야 함"

- ✓ Identity Shortcut: Zero-padding하여 차원을 맞추는 것
- ✓ Projection Shortcut: Linear Projection(1X1 convolution layer 통과) 으로 차원을 맞추는 것

Identity Shortcut의 성능이 떨어지는 이유 : Zero-padding한 영역에서는 residual learning이 되지 않았기 때문

C>B>A> Plain

•(A): zero-padding(identity) shortcut만 사용

•(B) : 차원이 같은경우 identity, 차원이 다른경우 projection shortcut 사용


•(C) : projection shortcut만 사용

model	top-1 err.	top-5 err.
VGG-16 [41]	28.07	9.33
GoogLeNet [44]	-	9.15
PReLU-net [13]	24.27	7.38
plain-34	28.54	10.02
ResNet-34 A	25.03	7.76
ResNet-34 B	24.52	7.46
ResNet-34 C	24.19	7.40
ResNet-50	22.85	6.71
ResNet-101	21.75	6.05
ResNet-152	21.43	5.71

### "3 by 3 convolution을 반복하는 점에서 VGGNet과 비슷"




3by 3 convolution을 더 많이 쌓아준 것




				50.1		152-layer Win
layer name	output size	18-layer	34-layer	50-layer	101-layer	152-layer
convl	112×112			$7 \times 7$ , 64, stride 2		
				3×3 max pool, stric	le 2	
conv2_x	56×56	$\left[\begin{array}{c} 3\times3,64\\ 3\times3,64 \end{array}\right]\times2$	$\begin{bmatrix} 3\times3, 64\\ 3\times3, 64 \end{bmatrix} \times 3$	$\begin{bmatrix} 1 \times 1, 64 \\ 3 \times 3, 64 \\ 1 \times 1, 256 \end{bmatrix} \times 3$	$\begin{bmatrix} 1 \times 1, 64 \\ 3 \times 3, 64 \\ 1 \times 1, 256 \end{bmatrix} \times 3$	$\begin{bmatrix} 1 \times 1, 64 \\ 3 \times 3, 64 \\ 1 \times 1, 256 \end{bmatrix} \times 3$
conv3_x	28×28	\[ \begin{array}{c} 3 \times 3, 128 \\ 3 \times 3, 128 \end{array} \] \times 2	\[ \begin{array}{c} 3 \times 3, 128 \\ 3 \times 3, 128 \end{array} \] \times 4	$\begin{bmatrix} 1 \times 1, 128 \\ 3 \times 3, 128 \\ 1 \times 1, 512 \end{bmatrix} \times 4$	$\begin{bmatrix} 1 \times 1, 128 \\ 3 \times 3, 128 \\ 1 \times 1, 512 \end{bmatrix} \times 4$	$\begin{bmatrix} 1 \times 1, 128 \\ 3 \times 3, 128 \\ 1 \times 1, 512 \end{bmatrix} \times 8$
conv4_x	14×14	$\left[\begin{array}{c} 3\times3,256\\ 3\times3,256 \end{array}\right]\times2$	\[ \begin{aligned} 3 \times 3, 256 \ 3 \times 3, 256 \end{aligned} \times 6 \]	$\begin{bmatrix} 1 \times 1, 256 \\ 3 \times 3, 256 \\ 1 \times 1, 1024 \end{bmatrix} \times 6$	$\begin{bmatrix} 1 \times 1, 256 \\ 3 \times 3, 256 \\ 1 \times 1, 1024 \end{bmatrix} \times 23$	$ \begin{bmatrix} 1 \times 1, 256 \\ 3 \times 3, 256 \\ 1 \times 1, 1024 \end{bmatrix} \times 36 $
conv5_x	7×7	$\left[\begin{array}{c} 3\times3,512\\ 3\times3,512 \end{array}\right]\times2$	$\left[\begin{array}{c} 3\times3,512\\ 3\times3,512 \end{array}\right]\times3$	$\begin{bmatrix} 1 \times 1, 512 \\ 3 \times 3, 512 \\ 1 \times 1, 2048 \end{bmatrix} \times 3$	$\begin{bmatrix} 1 \times 1, 512 \\ 3 \times 3, 512 \\ 1 \times 1, 2048 \end{bmatrix} \times 3$	$ \begin{bmatrix} 1 \times 1, 512 \\ 3 \times 3, 512 \\ 1 \times 1, 2048 \end{bmatrix} \times 3 $
	1×1		av	erage pool, 1000-d fc,	softmax	
FL	OPs	1.8×10 <sup>9</sup>	3.6×10 <sup>9</sup>	3.8×10 <sup>9</sup>	7.6×10 <sup>9</sup>	11.3×10 <sup>9</sup>

Table 1. Architectures for ImageNet. Building blocks are shown in brackets (see also Fig. 5), with the numbers of blocks stacked. Downsampling is performed by conv3\_1, conv4\_1, and conv5\_1 with a stride of 2.

#### "ResNet 50이상 모델 - Bottle Neck 구조"





<기본 Residual Block>

<Bottle Neck Residual Block>

1 by 1 필터를 통해 차원 축소 3 by 3 필터 통과 다시 1 by 1 필터를 통해 차원을 키워 줌

-> 피쳐 맵의 개수가 줄어들어 연산 량을 줄여줄 수 있음

# Conclusion




Figure 4. Training on ImageNet. Thin curves denote training error, and bold curves denote validation error of the center crops. Left: plain networks of 18 and 34 layers. Right: ResNets of 18 and 34 layers. In this plot, the residual networks have no extra parameter compared to their plain counterparts.

# Conclusion

	plain	ResNet
18 layers	27.94	27.88
34 layers	28.54	25.03

Top-1 validation error rates (%)

method	top-5 err. (test)	
VGG [41] (ILSVRC'14)	7.32	
GoogLeNet [44] (ILSVRC'14)	6.66	
VGG [41] (v5)	6.8	
PReLU-net [13]	4.94	
BN-inception [16]	4.82	
ResNet (ILSVRC'15)	3.57	

Top-5 test error rates (%) of ensembles

method	top-1 err.	top-5 err.
VGG [41] (ILSVRC'14)	-	8.43 <sup>†</sup>
GoogLeNet [44] (ILSVRC'14)	-	7.89
VGG [41] (v5)	24.4	7.1
PReLU-net [13]	21.59	5.71
BN-inception [16]	21.99	5.81
ResNet-34 B	21.84	5.71
ResNet-34 C	21.53	5.60
ResNet-50	20.74	5.25
ResNet-101	19.87	4.60
ResNet-152	19.38	4.49

Validation error rates (%) of single-model



이상 ADS 황성아 였습니다. 감사합니다.